

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

Evidenčné číslo: FIIT-16768-120897

Dávid Truhlář

**Výskum v oblasti technológie digitálneho
dvojčata**

Bakalárska práca

Vedúci záverečnej práce: Ing. Matej Petrík

Máj 2025

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

Evidenčné číslo: FIIT-16768-120897

Dávid Truhlár

Výskum v oblasti technológie digitálneho dvojčata

Bakalárska práca

Študijný program: Informatika

Študijný odbor: Informatika

Školiace pracovisko: Ústav počítačového inžinierstva a aplikovanej informatiky

Vedúci záverečnej práce: Ing. Matej Petrík

Máj 2025



ZADANIE BAKALÁRSKEJ PRÁCE

Študent: **Dávid Truhlár**
ID študenta: 120897
Študijný program: informatika
Študijný odbor: informatika
Vedúci práce: Ing. Matej Petrík
Vedúci pracoviska: Ing. Katarína Jelemenská, PhD.

Názov práce: **Výskum v oblasti technológie digitálneho dvojčata**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

Digitálne dvojča je inovatívna technológia, ktorá mení spôsob, akým chápeme a interagujeme s fyzickými objektami, procesmi či systémami. Digitálne dvojča je virtuálna alebo digitálna kópia fyzického objektu, systému alebo procesu, pričom sa snaží zachytiť a kopírovať čo najpresnejšie jeho vlastnosti. Technológia digitálneho dvojčata zohráva kľúčovú rolu v Priemysle 4.0 kvôli možnostiam monitorovania, simulácie a automatizácie v reálnom čase. Vďaka týmto možnostiam využitie tejto technológie umožňuje nové úrovne inovácie a optimalizácie naprieč rôznymi odvetvami a taktiež má potenciál akcelerovať vývoj v týchto oblastiach. Preskúmajte využitie technológie digitálneho dvojčata a jej aplikácie. Zamerajte sa na preskúmanie konceptu digitálneho dvojčata, na spôsob jeho implementácie a taktiež aj na dostupné technológie na jeho tvorbu. Vytvorte prehľad dostupných riešení, navrhnite spôsob vytvorenia jednoduchého digitálneho dvojčata, ktoré bude kópiou fyzického objektu alebo systému. Navrhnuté riešenie implementujte a overte jeho funkčnosť. Literatúra: 1. Singh, Maulshree, et al. "Digital twin: Origin to future." Applied System Innovation 4.2 (2021): 36. 2. Crespi, Noel, Adam T. Drobot, and Roberto Minerva. The Digital Twin. Cham: Springer International Publishing, 2023. 3. Jones, David, et al. "Characterising the Digital Twin: A systematic literature review." CIRP journal of manufacturing science and technology 29 (2020): 36-52.

Rozsah práce: 40

Termín odovzdania bakalárskej práce: 12. 05. 2025

Dátum schválenia zadania bakalárskej práce: 15. 04. 2025

Zadanie bakalárskej práce schválil: doc. Ing. Ján Lang, PhD. – garant študijného programu

Čestné prehlásenie

Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Bratislave, 12.5.2025

.....

Dávid Truhlář

PodĎakovanie

Touto cestou by som rád vyjadril úprimné poďakovanie všetkým, ktorí ma podporili a pomohli mi pri vypracovaní tejto bakalárskej práce.

Na prvom mieste patrí moja vďaka školiteľovi Ing. Matejovi Petríkovi za jeho odborné vedenie, ochotu, cenné rady a usmernenia, ktoré výrazne prispeli k realizácii tejto práce. Ďalej vyjadrujem poďakovanie Ing. Matejovi Janebovi za jeho čas a technické konzultácie v oblasti 5G technológií.

Osobitné poďakovanie patrí aj mojej rodine za prejavenu dôveru, trpezlivosť a neustálu podporu počas celého štúdia.

Obsah

1	Technický abstrakt	1
2	Laický abstrakt	3
3	Úvod	5
4	Formulácia problému a riešenie	7
4.1	Formulácia problému	7
4.2	Technický literárny prehľad	8
4.3	Prehľad riešenia na vysokej úrovni	10
4.4	Hodnotenie rizík	13
4.5	Technická reprodukovateľnosť a integrácia	14
4.6	Udržateľnosť a environmentálny dopad	17
4.7	Zamestnateľnosť	19
4.8	Tímová práca, diverzita a inklúzia	19
5	Záver	21
	Zoznam použitej literatúry	25
A	Používateľská príručka	
B	Harmonogram práce	

Zoznam obrázkov

4.1	Model zrkadlených priestorov	8
4.2	Architektúra komponentov Open5GS a UERANSIM	11
4.3	Architektúra systému: simulácia 5G siete, zber metrických dát a real-time klasifikácia s výstupom do Grafany.	12

Zoznam tabuliek

5.1	Výkon klasifikácie tried pre syntetické a reálne dáta.	21
-----	--	----

Zoznam použitých skratiek

AMF	Funkcia riadenia prístupu a mobility (Access and Mobility Management Function)
AUSF	Funkcia autentifikačného servera (Authentication Server Function)
BP	Bakalárska práca
DT	Digitálne dvojča (Digital Twin)
GDPR	Všeobecné nariadenie o ochrane údajov (General Data Protection Regulation)
gNB	Node B novej generácie (Next Generation Node B)
IoT	Internet vecí (Internet of Things)
IT	Informačné technológie
ML	Strojové učenie (Machine Learning)
PCF	Funkcia politiky a účtovania (Policy and Charging Function)
RAN	Rádiová prístupová sieť (Radio Access Network)
SMF	Funkcia riadenia relácií (Session Management Function)
UDM	Jednotná správa údajov (Unified Data Management)
UDR	Jednotné úložisko údajov (Unified Data Repository)
UE	Užívateľské zariadenie (User Equipment)
UPF	Funkcia používateľskej roviny (User Plane Function)

1 Technický abstrakt

5G siete predstavujú základ infraštruktúry pre kritické aplikácie s vysokými nárokmi na nízku latenciu a vysokú spoľahlivosť. V tomto kontexte môžu zohrávať digitálne dvojčatá (Digital Twin) kľúčovú úlohu pri simulácii, monitorovaní a optimalizácii siete v reálnom čase. Cieľom tejto práce je navrhnúť a implementovať klasifikačný systém využívajúci digitálne dvojča 5G siete, ktorý je schopný v reálnom čase identifikovať typ sieťovej prevádzky (Use Case - UC) pomocou metód strojového učenia.

Navrhnutý systém využíva nástroje Open5GS a UERANSIM na generovanie syntetických metrických dát zo šiestich typov sieťovej záťaže, pričom tieto scenáre pokrývajú ako bežné, tak aj anomálne správanie používateľov. Súčasne prebieha zber dát z reálnej siete a porovnanie rozložení metrík pomocou metód ako KL-divergencia a PCA vizualizácie. Po analýze prieniku medzi syntetickým a reálnym priestorom bol navrhnutý robustný výber metrík pomocou kombinácie Random Forest, RFE, SFS a permutačnej importance.

Výsledný model využíva LSTM architektúru optimalizovanú pomocou Batch normalizácie pre klasifikovanie stavu siete v reálnom čase. Model trénovaný výhradne na syntetických dátach dosiahol na reálnych dátach presnosť 13%, ktorá bola následne zlepšená pomocou online fine-tuningu založeného na správne označených UC hodnotách až na 50%. Model je nasadený v Docker kontejneroch, načítava

real-time metriky a predikcie sú exportované do Prometheus ako vlastné metriky. Celý systém je vizualizovaný v Grafane, vrátane dôveryhodnosti predikcie a verziovania modelu.

Práca potvrdzuje, že pri dôslednej doménovej analýze je možné trénovať použiteľný model výhradne na syntetických dátach a následne ho adaptovať na produkčné nasadenie v reálnej 5G infraštruktúre.

2 Laický abstrakt

Digitálne dvojča predstavuje virtuálny model reálneho systému, ktorý umožňuje sledovať a analyzovať jeho správanie v reálnom čase. V posledných rokoch si táto technológia našla uplatnenie v priemysle, doprave či zdravotníctve. V tejto práci sa venujem vytvoreniu digitálneho dvojčaťa pre 5G sieť s cieľom porozumieť, ako sa správa pri rôznych používateľských scenároch.

Pomocou voľne dostupných nástrojov som vytvoril softvérové prostredie, ktoré simuluje správanie reálnej mobilnej siete. Následne som zbieral dáta nielen zo simulácií, ale aj z reálnych zariadení pripojených do 5G siete. Tieto údaje zahŕňali napríklad počet pripojených používateľov či objem prenesených dát.

Hlavným cieľom bolo overiť, či je možné natrénovať model umelej inteligencie na simulovaných dátach a použiť ho na rozpoznávanie situácií v reálnej sieti. Takýto prístup je bezpečný, flexibilný a umožňuje testovanie aj zriedkavých alebo extrémnych scenárov bez zásahu do reálnej prevádzky.

Výsledný systém dokáže klasifikovať správanie siete podľa typických vzorcov a vytvára priestor pre budúce nasadenie monitorovania a správy sietí.

3 Úvod

Technológia digitálneho dvojčata (Digital Twin, DT) predstavuje jeden z najperspektívnejších prístupov v oblasti moderného softvérového inžinierstva [1] a telekomunikácií [2]. DT umožňuje vytvárať virtuálne repliky fyzických systémov, ktoré v reálnom čase zrkadlia ich správanie pomocou obojsmernej výmeny dát [3]. Takéto systémy nachádzajú uplatnenie v rôznych doménach vrátane priemyselnej výroby [4], zdravotníctva [5], dopravy a energetiky, kde umožňujú monitorovanie v reálnom čase, prediktívne riadenie a optimalizáciu procesov.

V oblasti mobilných sietí, najmä 5G, poskytujú DT nové možnosti v simulácii sieťového správania, včasnej detekcii anomálií a optimalizácii alokácie zdrojov [6]. 5G infraštruktúry sa vyznačujú vysokou mierou heterogenity, dynamiky a nárokmi na kvalitu služieb (QoS), čo výrazne komplikuje ich spravovanie a testovanie [2]. DT v tomto kontexte umožňuje testovanie rôznych scenárov v bezpečnom virtuálnom prostredí bez rizika výpadku služby či narušenia integrity dát.

Kľúčovou výzvou pri návrhu DT pre 5G siete je však zabezpečenie dostatočnej vernosti simulácie. Otázna zostáva najmä generalizovateľnosť modelov trénovaných výhradne na syntetických dátach voči reálnym podmienkam, ktoré sú komplexnejšie, menej predvídateľné a menej kontrolované. Cieľom tejto bakalárskej práce je preskúmať túto výzvu prostredníctvom návrhu a implementácie jednoduchého digitálneho dvojčata pre 5G sieť, postaveného na open-source nástrojoch Open5GS

[7] a UERANSIM [8], a vyhodnotiť schopnosť modelov klasifikovať správanie siete v reálnom čase na základe synteticky získaných metrík.

4 Formulácia problému a riešenie

4.1 Formulácia problému


V oblasti 5G sietí predstavujú DT perspektívny nástroj na bezpečné testovanie, monitorovanie a optimalizáciu správania siete. Vysoké nároky 5G na nízku latenciu, spoľahlivosť a flexibilitu riadenia zároveň vyžadujú schopnosť rýchlo identifikovať rôzne typy bežného správania, ale aj anomálie a útoky. Aby bolo možné efektívne trénovať klasifikačné modely bez rizika pre produkčnú infraštruktúru, je potrebné simulovať rôzne scenáre v kontrolovanom prostredí - DT.

Kľúčovým problémom však zostáva otázka, do akej miery môžu modely trénované výhradne na syntetických dátach zo simulovaných prostredí, ako Open5GS a UERANSIM, generalizovať na reálne siete, keďže výrazný nesúlad medzi syntetickými a reálnymi dátami môže obmedziť praktickú využiteľnosť takto vytvorených modelov.

Cieľom tejto bakalárskej práce je preto navrhnúť a implementovať jednoduché DT 5G siete a experimentálne overiť limity využitia syntetických Open5GS metrík na trénovanie klasifikačných modelov schopných rozpoznať reálne správanie siete.

4.2 Technický literárny prehľad

DT predstavuje koncept virtuálnej repliky fyzického objektu alebo systému, ktorá je schopná v reálnom čase odrážať jeho aktuálny stav prostredníctvom obojsmernej výmeny dát (pozri Obr. 4.1) [9]. Na rozdiel od tradičných modelov alebo simulácií je DT charakteristické dynamickým aktualizovaním svojho správania na základe dát zo sledovaného objektu [10]. Tento koncept nachádza uplatnenie naprieč viacerými odvetvami vrátane výroby, zdravotníctva, dopravy či energetiky [6].



Obr. 4.1: Model zrkadlených priestorov (Mirrored Spaces Model) tak, ako ho vo svojej práci navrhol Grieves [11]. Tento model sa skladá z troch komponentov - reálny priestor (Real Space), virtuálny priestor (Virtual space) a spájací mechanizmus (Linking Mechanism) [9], ktorý prúdi automatizovane oboma smermi medzi týmito priestormi. Virtuálny priestor vytvára digitálnu reprezentáciu reálnych objektov a podporuje viacero virtuálnych systémov na analýzu, simuláciu alebo predikciu správania fyzických objektov.

Vo svojom výskume Enders a Hořbachová [1] identifikovali sektory, kde je používanie DT najrozšírenejšie. Patria sem výroba [12], letecký priemysel [13], energetika [14], automobilový priemysel [15], námorníctvo [16], petrochemický priemysel [17],

poľnohospodárstvo [18], zdravotníctvo [19], verejný sektor [20] a ťažba [21].

Taktiež identifikovali tri hlavné využitia DT v týchto oblastiach [2]: ovládanie, simulovanie a monitorovanie. To však nepokrýva všetky možnosti a spôsoby využitia. DT dnes nájde uplatnenie aj pri dizajnovaní, validácii, predchádzaní chýb, trénoch a optimalizácii.

Vývoj digitálnych dvojčiat je podporený množstvom softvérových nástrojov líšiacich sa funkcionalitou a cenou. ANSYS Twin Builder je zameraný na presné fyzikálne modelovanie procesov (mechanika, elektromagnetizmus) a je vhodný pre tvorbu inžinierskych DT, pričom patrí medzi najnákladnejšie riešenia [22]. Siemens MindSphere ponúka cloudovú platformu na správu dát a monitoring zariadení v priemyselných aplikáciách, s cenou závislou od rozsahu nasadenia [23]. MATLAB a Simulink ponúkajú flexibilnú platformu pre tvorbu digitálnych dvojčiat s dôrazom na simuláciu dynamických systémov, modelovanie riadiacich algoritmov a predikciu správania [24]. Alternatívou bez licenčných nákladov je vlastná implementácia DT prostredím, kde je možné vytvoriť simulované kópie vybraných častí systému. Napríklad v oblasti 5G možno pomocou Open5GS a UERANSIM zostaviť základné virtuálne repliky siete, ktoré v kombinácii s vhodne naprogramovanými skriptami umožňujú budovanie DT.

Ak sa chceme pozrieť na reálne aplikácie DT, Huawei implementoval DT na monitorovanie výrobných liniek [25], zatiaľ čo mestá ako Bristol [26] či Singapur [27] používajú DT na efektívne riadenie inteligentných mestských systémov. V týchto scenároch DT umožňuje predikciu zlyhaní, optimalizáciu zdrojov a minimalizáciu prestojov.

V oblasti telekomunikácií sa koncept DT začína uplatňovať na monitorovanie a optimalizáciu sieťových zdrojov v reálnom čase. 5G siete sú charakteristické vysokými nárokmi na nízku latenciu, spoľahlivosť a dynamické riadenie. DT v tomto

prostredí umožňuje simuláciu zmien konfigurácie, predikciu anomálií a podporu rozhodovania bez rizika zásahu do produkčnej infraštruktúry [28].

Odborná literatúra zároveň upozorňuje, že jednou z hlavných výziev pre DT v oblasti 5G je zabezpečenie dostatočne realistickej reprezentácie dynamických sieťových podmienok, vrátane mobility používateľov, variability záťaže a správy QoS [29]. Niektoré open-source simulačné nástroje ako Open5GS alebo UERANSIM, umožňujú tvorbu syntetických dát pokrývajúcich štandardné scenáre správania siete [30], avšak plné zachytenie komplexity reálnej prevádzky zostáva otvorenou výzvou.

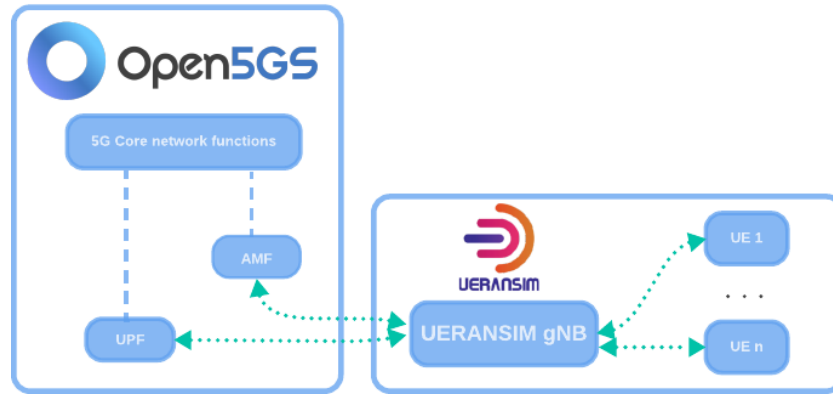
Z týchto poznatkov vyplýva, že ďalší výskum by sa mal sústrediť na rozšírenie simulačných možností, kombinovanie syntetických a reálnych dát a na metodiky validácie modelov v podmienkach, ktoré čo najviac odrážajú reálnu prevádzku 5G sietí.

4.3 Prehľad riešenia na vysokej úrovni

Navrhnuté riešenie pozostáva z modulárneho systému na báze DT, ktorého cieľom je analyzovať a klasifikovať správanie 5G siete v kontrolovanom prostredí. Vytvorené DT simuluje vybrané komponenty reálnej siete a umožňuje generovanie syntetických dát, ich zber, spracovanie a následnú aplikáciu modelov strojového učenia. Architektúra systému bola navrhnutá s dôrazom na rozšíriteľnosť, modularitu a experimentálnu reprodukovateľnosť.

Open5GS je open-source implementácia 5G jadra siete, ktorá slúži ako základná riadiaca infraštruktúra pre prichádzajúce spojenia. V navrhnutom riešení zodpovedá za autentifikáciu zariadení, správu session a prideľovanie IP adries.

UERANSIM je emulátor RAN prístupu, ktorý generuje simulovaných používateľov (UE), ktorí sa pripájajú do siete (pozri Obr. 4.2) cez definované scénare. Umožňuje flexibilne konfigurovať počet zariadení, typy prevádzky a časovanie spojení.



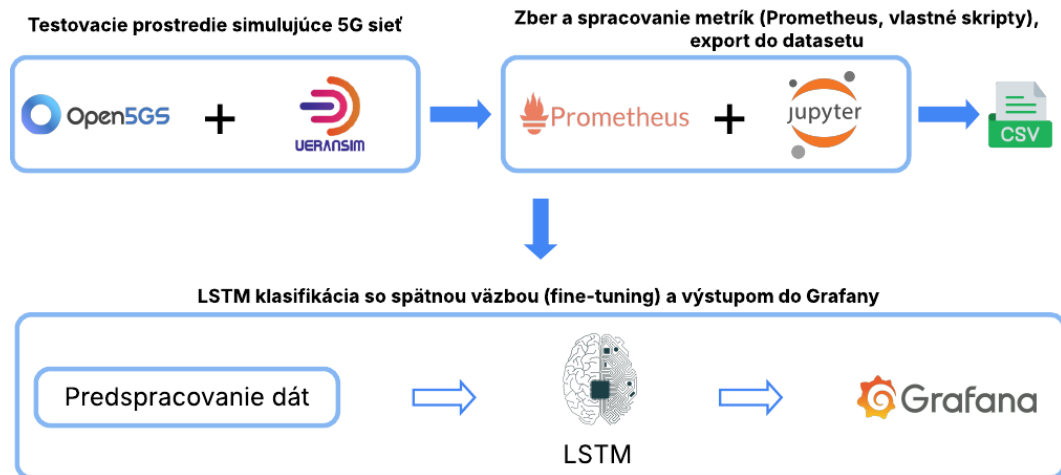
Obr. 4.2: Architektúra jednotlivých komponentov Open5GS a UERANSIM a ich vzájomné prepojenie. Open5GS je rozdelené na riadiacu rovinu a rovinu užívateľských dát a obe tieto roviny sú napojené na gNB, ku ktorým sa môžu pripájať zariadenia.

Monitorovacia infraštruktúra pozostáva z nástrojov Prometheus, Grafana, Promtail a logwatcher.py. Prometheus zberá metriky zo siete a systémových zdrojov, ktoré sú vizualizované pomocou Grafany. Logwatcher je vlastný Python skript, ktorý analyzuje logy z Open5GS a exportuje vlastné metriky ako napr. počet aktívnych UE či SUCI identifikátory.

Skripty na simuláciu scenárov (UC) slúžia na spúšťanie preddefinovaných testovacích situácií. Každý UC definuje počet zariadení, objem prenesených dát a časovanie spojení, čím vytvára realistické syntetické zaťaženie siete.

Predspracovanie dát a výber metrík (EDA, preprocessing, feature selection) boli vykonané raz pred tréňovaním modelu, s cieľom optimalizovať vstup pre model strojového učenia. Výber metrických premenných bol podporený metódami založenými na rozhodovacích stromoch a permutačnej dôležitosti.

Modely strojového učenia boli implementované pomocou LSTM modelov, ktoré sú vhodné pre sekvenčné dáta. Model bol natrénovaný na syntetických dátach a neskôr testovaný na dátach z reálnej siete.



Obr. 4.3: Zariadenia generované pomocou UERANSIM sa pripájajú k jadru siete v Open5GS, ktoré loguje udalosti a vystavuje metriky. Tieto údaje sú zbierané pomocou Promethea a logwatcher.py skriptu. Výstupy sú agregované do datasetu, ktorý sa ďalej spracúva v prostredí Jupyter Notebook. Po spracovaní sa dáta využívajú na tréning a testovanie modelov strojového učenia. Vizualizácia metrických údajov prebieha súbežne v Grafane.

Modularita kontajnerizovaného riešenia založeného na Docker Compose umožňuje jednoduché nasadenie a replikáciu prostredia. Open-source komponenty boli zvolené kvôli dostupnosti a možnosti detailnej konfigurácie siete. Použitie syntetických scenárov poskytuje kontrolu nad testovaným správaním bez rizika ovplyvnenia reálnej prevádzky. LSTM siete boli zvolené vďaka schopnosti modelovať časové závislosti, ktoré sú kľúčové pri klasifikácii sieťového správania. Kombinácia reálneho a syntetického vstupu umožňuje overiť možnosti generalizácie modelov v telekomunikačnom prostredí.

4.4 Hodnotenie rizík

Implementácia digitálneho dvojčata 5G siete v kombinácii s klasifikačným modelom umelej inteligencie prináša niekoľko potenciálnych rizík, ktoré by mohli ovplyvniť presnosť, stabilitu a praktickú využiteľnosť riešenia [31].

Jedným z najvýznamnejších rizík je nedostatočná kvalita vstupných dát. Vzhľadom na to, že systém sa bude spoliehať na syntetické metriky generované v simulovanom prostredí, existuje riziko, že tieto dáta nebudú dostatočne reprezentatívne pre správanie reálnej siete. To by mohlo negatívne ovplyvniť schopnosť modelu generalizovať. Ako mitigácia sa predpokladá testovanie viacerých variantov simulácií, aplikácia metód validácie [32] (napr. krížová validácia) a neskôr prípadné doplnenie reálnych dátových vstupov [33].

Ďalším rizikom je obmedzený čas dostupný na zber a spracovanie dát. Experimentálne simulácie si vyžadujú značné množstvo iterácií a manuálnej prípravy scenárov, čo môže limitovať rozsah a kvalitu datasetu pre modelovanie [34]. Mitigáciou je dôsledné plánovanie simulácií, skriptovanie opakovaných činností a prioritizácia najrelevantnejších scenárov.

V oblasti softvérovej architektúry je potrebné počítať s možnou nekompatibilitou medzi jednotlivými komponentmi ako Open5GS, UERANSIM, Prometheus, Docker a vlastné skripty. Vzhľadom na to, že ide o open-source riešenia vyvíjané nezávisle, ich integrácia môže byť nestabilná alebo nedostatočne zdokumentovaná [35]. Navrhovanou stratégiou je modulárne nasadzovanie systémov, priebežné testovanie a dôsledná kontrola konfigurácií v menších izolovaných častiach.

Riziko predstavuje aj nedostatočná synchronizácia časových pečiatok medzi komponentmi, čo môže ovplyvniť presnosť dátových okien pre LSTM model. Tento

problém je možné mitigovať precíznym logovaním timestampov a synchronizáciou systémového času medzi kontajnermi.

Z pohľadu bezpečnosti a etiky sa pri použití simulovanej siete s fiktívnymi údajmi a v uzavretom prostredí eliminuje riziko úniku osobných údajov či konfiguračných súborov. Napriek tomu je vhodné minimalizovať citlivosť konfigurácií pomocou .env súborov [36] a testovať výhradne na syntetických identitách a IMSI.

4.5 Technická reprodukovateľnosť a integrácia

Navrhnuté riešenie DT 5G siete bolo navrhnuté s dôrazom na experimentálnu reprodukovateľnosť a jednoduché nasadenie. Celý projekt je dostupný vo verejnom repozitári na platforme GitHub¹, vrátane kompletného zdrojového kódu, Docker konfigurácie a skriptov pre real-time klasifikáciu.

K spusteniu základného systému stačí klonovanie repozitára pomocou `git clone`, pričom je potrebné, aby bol na cieľovom systéme nainštalovaný git vo verzii 2.39.5 a Docker vo verzii 28.0.1. Všetky závislosti sú zabudované do kontajnerov a celý systém je orchestrovaný pomocou `docker compose`. Po nakonfigurovaní premenných prostredia v súbore `.env` a inicializácii MongoDB databázy s preddefinovanými UE, sa systém spustí jedným príkazom:

```
docker compose -f deploy-all.yaml up -build -d
```

Po nasadení komponentov je možné cez webové rozhranie Open5GS (port 9999) overiť funkčnosť jadra siete a cez Grafanu (port 3000) vizualizovať stav siete v reálnom čase. Konfigurácia UERANSIM gNB a UEs je súčasťou repozitára a umožňuje simuláciu dynamického sieťového zaťaženia.

¹<https://github.com/xtruhlar/5GDigitalTwin>

Zber dát

Zber dát pre tréovanie a testovanie klasifikačných modelov bol realizovaný samostatne pre syntetickú a reálnu prevádzku. V prípade syntetických dát boli experimenty plne automatizované: systém bežal v Docker Compose prostredí, pričom skript každú sekundu scrapoval metriky z Prometheusa, extrahoval informácie z logov Open5GS a zaznamenával aktívny stav zo súboru, ktorý obsahoval aktuálny UC. Každý riadok datasetu tak obsahoval timestamp, sieťové metriky, informácie o logoch a aktuálny label podľa spusteného UC.

Pri zbere reálnych dát bola situácia odlišná. Merania prebiehali v laboratórnom prostredí so skutočnými zariadeniami pripojenými do nezávislej 5G siete. Presný čas začiatku a konca každého používateľského scenára bol zaznamenaný manuálne. Po experimente boli všetky relevantné logy skopírované a vložené do preddefinovanej zložky, ktorú čítal ten istý skript. Na základe časového okna experimentu boli metriky zozbierané z Prometheusa a synchronizované s logmi. Pridávanie stĺpca s číslom UC do jednotlivých riadkov prebiehalo podľa známeho začiatku a konca testovaného UC. Tým bola zabezpečená konzistentnosť medzi stavom siete a cieľovou premennou modelu.

Finálny dataset pre každý experiment bol exportovaný vo formáte CSV, pričom štruktúra bola zhodná pre syntetické aj reálne dáta.

Tréovanie modelov a použitie výstupov

Na zabezpečenie rovnakých výsledkov tréovania boli dodržané nasledovné podmienky:

- vo všetkých notebookoch sú fixované **seed hodnoty**, veľkosť **batchu**, počet

epoch, architektúra modelu a stratifikované rozdelenie datasetu,

- krok 1: spustenie `eda_feature_selection.ipynb`, ktorý vytvorí súbor `selected_features.json`,
- krok 2: spustenie `dataset_processing.ipynb`, ktorý vygeneruje `X_scaled.npy`, `y_labels.npy` a `scaler.joblib`,
- krok 3: spustenie `lstm_preprocessing.ipynb`, ktorý sekvenuje dáta a exportuje ich vo formáte `X_train.npy`, `y_train.npy`, `X_test.npy`, `y_test.npy`,
- krok 4: tréning modelov pomocou `lstm_*.ipynb` na syntetických dátach,
- krok 5: vyhodnotenie na reálnych dátach v `eval_results_real_data.ipynb`,

Predtrénované modely sú uložené v

`/5GDigitalTwin/Implementation/data/Model/trained_models`.

Real-time klasifikácia a online fine-tuning

Kľúčovým komponentom riešenia je vlastný skript `log_watcher.py`, ktorý slúži nielen na spracovanie logov z Open5GS (AMF), ale aj na priebežnú predikciu aktuálneho UC pomocou LSTM modelu a jeho online fine-tuning na najnovších dátach. Skript beží ako samostatný proces v jednom z Docker kontajnerov a je automaticky spúšťaný pri štarte systému.

Každú sekundu skript načíta nové riadky z logov pomocou `pygtail`, extrahuje stav jednotlivých UE zariadení (registrácia, deregistrácia, trvanie relácií) a z týchto údajov vypočítava vlastné metriky. Zároveň načíta posledných 60 záznamov z generovaného CSV súboru, normalizuje ich, a použije ako vstup do už natrénovaného LSTM modelu. Výsledná predikcia je exportovaná ako vlastná Prometheus metrika spolu s dôverou predikcie a stratou (loss) počas tréningu.

Simulácia používateľských scenárov

Na automatizovanú simuláciu používateľských scenárov (UCs) bol vytvorený skript `running_network.py`, ktorý náhodne vyberá a spúšťa jednotlivé scenáre zo súborov `uc1.py` až `uc6.py`. Každý z týchto šiestich skriptov reprezentuje špecifický typ zaťaženia 5G siete, ako napríklad opakovanú registráciu používateľov, sťahovanie veľkého objemu dát, dlhodobé pripojenie s minimálnou aktivitou či anomálnu autentizáciu.

Skript `running_network.py` funguje ako orchestrátor – každých niekoľko minút náhodne vyberie niektorý z UC skriptov, spustí ho v pozadí ako samostatný proces a následne ho po skončení ukončí. Informáciu o aktuálne bežiacom scenári zapisuje do súboru, ktorý slúži ako jediný zdroj pravdy pre labelovanie zberaných metrických dát počas trvania experimentu.

Každý `ucX.py` skript (kde $X \in \{1, \dots, 6\}$) obsahuje definíciu počtu zariadení, konfiguráciu ich sieťového zaťaženia a dĺžku trvania simulácie. Scenáre boli navrhnuté tak, aby pokrývali reprezentatívne prípady bežnej aj abnormálnej prevádzky v 5G sieti. Táto architektúra umožňuje nielen spoľahlivý zber syntetických dát, ale aj jednoduché rozšírenie systému o ďalšie prípady použitia bez zásahu do zvyšku infraštruktúry.

4.6 Udržateľnosť a environmentálny dopad

DT predstavujú konceptuálne aj prakticky významný prístup k optimalizácii prevádzkových procesov, ktorý v porovnaní s fyzickým testovaním výrazne znižuje spotrebu zdrojov, produkciu odpadu a prevádzkové riziká [37]. V kontexte návrhu DT 5G siete, implementovaného v rámci tejto práce, bola environmentálna udrža-

teľnosť reflektovaná v niekoľkých rovinách.

Z pohľadu výpočtovej náročnosti bola celá infraštruktúra navrhnutá s cieľom minimalizovať energetickú záťaž. Všetky komponenty boli nasadené na lokálnom výpočtovom uzle bez použitia centralizovaných cloudových služieb alebo akcelrátorov typu GPU. Kombinácia kontajnerizovaných služieb (Docker Compose) a open-source softvérových nástrojov (Open5GS, UERANSIM, Prometheus, Grafana) umožnila zabezpečiť nízku spotrebu zdrojov pri zachovaní dostatočnej funkcionality pre experimentálne overenie konceptu [38, 39].

V širšom zmysle sú DT považované za technológiu s potenciálom znižovať uhlíkovú stopu prostredníctvom presnejšej správy sietí, prediktívnej údržby a minimalizácie potreby fyzických zásahov do infraštruktúry [40, 41]. Aj keď prediktívne modelovanie nebolo predmetom tejto práce, implementovaný systém poskytuje základ, na ktorom je možné budovať systémy podporujúce rozhodovanie s pozitívnym environmentálnym dopadom [42].

Navyše, architektúra riešenia je modularizovaná, čo umožňuje selektívnu údržbu a výmenu komponentov bez nutnosti reінštalácie celého systému. Takýto návrhový prístup je v súlade s princípmi zeleného softvérového inžinierstva, ktoré zdôrazňujú znižovanie energetických nárokov a podporu dlhodobej životnosti softvérových riešení [43].

Navrhnutý systém teda nielenže zohľadňuje technologickú efektivitu a experimentálnu hodnotu, ale zároveň reflektuje požiadavky na environmentálnu udržateľnosť v oblasti návrhu a testovania moderných komunikačných systémov.

4.7 Zamestnateľnosť

Táto bakalárska práca, zameraná na rozvoj teoretických znalostí v oblasti DT v spojení s praktickou implementáciou a optimalizáciou 5G sietí, vedie k rozšíreniu zručností vo viacerých kľúčových oblastiach technologického sektora. V neposlednom rade strojové učenie, použité na klasifikáciu stavu implementovaného DT, zasahuje aj do oblasti dátovej vedy.

Vďaka formátu práce autori prejdú celým cyklom realizácie projektu, od prieskumu technológií cez návrh až po implementáciu a testovanie. Týmto získajú ucelený a komplexný pohľad na vývoj a riadenie softvérových projektov, ako aj na plánovanie, organizáciu a efektívnu komunikáciu.

Takáto kombinácia technických, projektových a komunikačných schopností môže významne zvýšiť hodnotu autorov na trhu práce, najmä v budúcnosti, keďže problematika DT a 5G sietí je stále viac žiadaná a nachádza uplatnenie v rôznych odvetviach.

4.8 Tímová práca, diverzita a inklúzia

Na vypracovaní tejto bakalárskej práce som síce pracoval samostatne, no viaceré časti riešenia by neboli realizovateľné bez odbornej podpory a spolupráce s ďalšími osobami a komunitami.

Počas celého vývoja som úzko spolupracoval so školiteľom Ing. Matejom Petříkom, ktorý mi poskytol dôležité usmernenia v oblasti DT, návrhu experimentov, spracovania dát a validácie výsledkov. V technických otázkach týkajúcich sa 5G sietí, konfigurácie Open5GS a správneho zberu metrických údajov zo siete som

mal možnosť konzultovať s Ing. Matejom Janebom, ktorý sa aktívne podieľal na overovaní konfigurácie experimentálnej infraštruktúry a asistoval aj pri vytváraní reálneho datasetu v kontrolovanom laboratórnom prostredí.

Dôležitou súčasťou riešenia bola aj interakcia s komunitou vývojárov open-source nástroja UERANSIM. V rámci otvorenej komunikácie som kontaktoval hlavného autora projektu Aliho Güngöra so žiadosťou o objasnenie spracovania RRC Release signálov, ktoré v oficiálnej verzii nástroja absentovali. Tento typ spolupráce prispel k lepšiemu pochopeniu limitov dostupných nástrojov a ukázal význam komunitne vyvíjaného softvéru pri budovaní výskumných riešení.

Práca zohľadňuje princípy inklúzie tým, že všetky skripty a výstupy sú dokumentované, konfigurovateľné a prístupné pre širšiu výskumnú komunitu bez obmedzenia technologickej platformy či licencie. Prostredníctvom modularity riešenia, dôrazu na open-source a dokumentovanej kontajnerizácie je výstup tejto práce plne replikovateľný a využiteľný aj pre iných výskumníkov s rôznym zázemím a úrovňou odbornosti.

5 Záver

V rámci tejto bakalárskej práce bol navrhnutý a implementovaný základný model digitálneho dvojčaťa (DT) pre 5G sieť, ktorý umožňuje simuláciu správania siete a zber dát z fyzickej i simulovanej infraštruktúry. Použitím nástrojov Open5GS a UERANSIM bol vytvorený kontrolovaný experimentálny priestor, v ktorom bolo možné testovať rôzne používateľské scenáre bez zásahu do reálnej siete. Výsledky ukazujú, že klasifikátory trénované výhradne na syntetických dátach dosahovali výrazne horšiu presnosť pri aplikácii na reálne dáta (44%), v porovnaní so 96.3% presnosťou na dátach zo simulácie. Tento pokles jasne signalizuje rozdiel medzi reálnym a simulovaným sieťovým správaním a zdôrazňuje potrebu spoľahlivých metód prenosu znalostí medzi týmito dvoma doménami.

Tabuľka 5.1: Výkon klasifikácie tried pre syntetické a reálne dáta.

Model	Accuracy	Precision	F1-Score	Recall
Synthetic dataset				
<i>Base Model</i>	0.949	0.950	0.949	0.949
<i>Robust Model</i>	0.900	0.905	0.900	0.900
<i>BatchNorm Model</i>	0.963	0.964	0.963	0.963
<i>Model with Attention</i>	0.914	0.918	0.914	0.914
Real dataset				
<i>Base Model</i>	0.14	0.06	0.04	0.14
<i>Robust Model</i>	0.44	0.25	0.29	0.44
<i>BatchNorm Model</i>	0.21	0.16	0.17	0.21
<i>Model with Attention</i>	0.16	0.03	0.05	0.16

Tieto zistenia poukazujú na viaceré limity implementovaného prístupu, ktoré je potrebné otvorene pomenovať. V prvom rade sa ukázalo, že syntetické metriky generované pomocou Open5GS majú obmedzenú schopnosť zachytiť komplexitu reálneho sieťového správania. Chýba im detailná reprezentácia QoS mechanizmov, realistický prenos na aplikačnej vrstve, ako aj podpora mobility, čo výrazne znižuje použiteľnosť týchto simulácií ako základ pre trénovanie modelov s dobrou generalizačnou schopnosťou. Hoci boli testované viaceré architektúry klasifikačných modelov (vrátane attention mechanizmu a batch normalizácie), výkonnosť na reálnych dátach ostávala nízka, čo naznačuje, že problém spočíva predovšetkým v obmedzenej kvalite dát. Navyše, použité metriky sa týkali výlučne core vrstvy, pričom chýbali detailnejšie údaje z RAN vrstvy, ako napríklad parametre rádiového signálu alebo využitie fyzických kanálov. Z pohľadu reálneho experimentálneho zberu bola práca obmedzená na malý počet zariadení, krátke trvanie meraní, čo mohlo ovplyvniť robustnosť výstupov. Hoci väčšina simulácií reprezentovala štandardné správanie, v jednom z prípadov bol zaradený aj anomálny scenár s odmietnutím pripojenia na základe neplatného IMSI, čo pomohlo zvýšiť rozmanitosť dát.

Práca ukazuje, že real-time klasifikácia a online trénovanie modelov je technicky realizovateľné aj v rámci jednoduchého DT, hoci zatiaľ len pri použití syntetických dát. Výsledky tejto práce zároveň naznačujú, že DT môžu nájsť uplatnenie v oblasti riadenia a optimalizácie 5G sietí – predovšetkým ako nástroj na bezpečné testovanie sieťových zmien, včasné odhaľovanie anomálií a trénovanie systémov umelej inteligencie mimo produkčného prostredia. Do budúcnosti by mal byť výskum orientovaný na zvýšenie vernosti simulácií a zlepšenie kvality dát použitých na trénovanie modelov. Za účelom premostenia medzi syntetickými a reálnymi dátami sa ako perspektívna javí kombinácia metrických údajov z Open5GS s dátami zachytenými v podobe paketov (PCAP), čo umožní extrahovať dotatočné charakteristiky sieťového správania a vrstviť informácie naprieč L2–L7. Zároveň je potrebné

preskúmať možnosti aplikácie pokročilých doménovo adaptačných techník, ktoré by mohli znížiť závislosť na rozsiahlych reálnych datasetoch.

Výzvou do budúcnosti ostáva rozšíriť real-time prístup aj na reálne sieťové prostredie a uzavrieť spätnú regulačnú slučku – teda umožniť systému nielen detegovať anomálie v reálnom čase, ale aj autonómne reagovať vhodnou rekonfiguráciou siete alebo notifikáciou správcu. Takýto obojsmerný tok dát medzi fyzickým a digitálnym prostredím predstavuje ďalší krok smerom k autonómnym, adaptívnym sieťam piatej generácie.

Zoznam použitej literatúry

- [1] Martin Enders a Nadja Hoßbach. “Dimensions of Digital Twin Applications - A Literature Review”. In: aug. 2019.
- [2] Maulshree Singh et al. “Applications of Digital Twin across Industries: A Review”. In: *Applied Sciences* 12 (jún 2022), s. 5727. DOI: 10.3390/app12115727.
- [3] Alberto Mozo et al. “B5GEMINI: Digital Twin Network for 5G and Beyond”. In: *NOMS 2022-2022 IEEE/IFIP Network Operations and Management Symposium*. 2022, s. 1–6. DOI: 10.1109/NOMS54207.2022.9789810.
- [4] Feng Xiang et al. “Digital Twin Driven Green Material Optimal-Selection towards Sustainable Manufacturing”. In: *Procedia CIRP* 81 (2019). 52nd CIRP Conference on Manufacturing Systems (CMS), Ljubljana, Slovenia, June 12-14, 2019, s. 1290–1294. ISSN: 2212-8271. DOI: <https://doi.org/10.1016/j.procir.2019.04.015>. URL: <https://www.sciencedirect.com/science/article/pii/S2212827119306298>.
- [5] *From Digital Twin to Improved Patient Experience — siemens-healthineers.com*. <https://www.siemens-healthineers.com/sk/news/mso-digital-twin-mater.html>. [Accessed 29-12-2024].
- [6] Huan X. Nguyen et al. “Digital Twin for 5G and Beyond”. In: *IEEE Communications Magazine* 59.2 (2021), s. 10–15. DOI: 10.1109/MCOM.001.2000343.
- [7] Open5GS. <https://github.com/open5gs/open5gs>. 2017.

- [8] Ali Güngör. *UERANSIM*. <https://github.com/aligungr/UERANSIM>. 2020.
- [9] Maulshree Singh et al. “Digital Twin: Origin to Future”. In: *Applied System Innovation* 4 (máj 2021), s. 36. DOI: 10.3390/asi4020036.
- [10] Roberto Verdecchia et al. “Network Digital Twins: A Systematic Review”. In: *IEEE Access* 12 (2024), s. 145400–145416. DOI: 10.1109/ACCESS.2024.3453034.
- [11] Michael Grieves. “Origins of the Digital Twin Concept”. Aug. 2016. DOI: 10.13140/RG.2.2.26367.61609.
- [12] Guodong Shao a Moneer Helu. “Framework for a digital twin in manufacturing: Scope and requirements”. In: *Manufacturing Letters* 24 (2020), s. 105–107. ISSN: 2213-8463. DOI: <https://doi.org/10.1016/j.mfglet.2020.04.004>. URL: <https://www.sciencedirect.com/science/article/pii/S2213846319301312>.
- [13] Eric Tuegel et al. “Reengineering Aircraft Structural Life Prediction Using a Digital Twin”. In: *International Journal of Aerospace Engineering* 2011 (jan. 2011). DOI: 10.1155/2011/154798.
- [14] Anton Rassõlkin et al. “Implementation of Digital Twins for electrical energy conversion systems in selected case studies”. In: *Proceedings of the Estonian Academy of Sciences* 70 (jan. 2021), s. 19–39. DOI: 10.3176/proc.2021.1.03.
- [15] P.K. Rajesh et al. “Digital Twin of an Automotive Brake Pad for Predictive Maintenance”. In: *Procedia Computer Science* 165 (2019). 2nd International Conference on Recent Trends in Advanced Computing ICRTAC -DISRUP - TIV INNOVATION , 2019 November 11-12, 2019, s. 18–24. ISSN: 1877-0509. DOI: <https://doi.org/10.1016/j.procs.2020.01.061>. URL: <https://www.sciencedirect.com/science/article/pii/S1877050920300697>.

- [16] DNV GL Maritime. *Digital Twin Report for DMA: Digital Twins for Blue Denmark*. Tech. spr. [Accessed 29-12-2024]. Danish Maritime Authority, 2018.
- [17] Sophie Menard. *3 ways digital twins are going to help improve oil and gas maintenance and operations - linkedin.com*. <https://www.linkedin.com/pulse/3-ways-digital-twins-going-help-improve-oil-gas-sophie-menard/>. [Accessed 29-12-2024]. 2017.
- [18] José Monteiro et al. “Towards Sustainable Digital Twins for Vertical Farming”. In: *2018 Thirteenth International Conference on Digital Information Management (ICDIM)*. 2018, s. 234–239. DOI: 10.1109/ICDIM.2018.8847169.
- [19] Carlos Miskinis. *Disrupting The Healthcare Industry Using Digital Twin Technology — challenge.org*. <https://www.challenge.org/insights/digital-twin-in-healthcare/>. [Accessed 29-12-2024]. 2018.
- [20] Joe David, Andrei Lobov a Minna Lanz. “Learning Experiences Involving Digital Twins”. In: *IECON 2018 - 44th Annual Conference of the IEEE Industrial Electronics Society*. Okt. 2018, s. 3681–3686. DOI: 10.1109/IECON.2018.8591460.
- [21] Carlos Miskinis. *The Impact of Digital Twins Technology in Mining and Mineral Extraction — challenge.org*. <https://www.challenge.org/insights/digital-twin-in-mining/>. [Accessed 29-12-2024]. 2018.
- [22] ANSYS Inc. *ANSYS Twin Builder: Simulation-driven Digital Twins*. Accessed: 2024-04-29. 2023. URL: <https://www.ansys.com/products/digital-twin/ansys-twin-builder>.
- [23] Siemens AG. *MindSphere: Industrial IoT as a service solution*. Accessed: 2024-04-29. 2023. URL: <https://siemens.mindsphere.io/>.
- [24] MathWorks. *What Is a Digital Twin?* Accessed: 2024-04-29. 2023. URL: <https://www.mathworks.com/discovery/digital-twin.html>.

- [25] Huawei. *Site Digital Twins Based 5G Digital Engineering Solution*. <https://www.huawei.com/en/news/2020/2/site-digital-twins-based-5g-digital-engineering-solution>. Accessed: 2024-12-03. 2020.
- [26] Paul Wilson. “State of smart cities in UK and beyond”. In: *IET Smart Cities* 1.1 (2019), s. 19–22. DOI: <https://doi.org/10.1049/iet-smc.2019.0024>. eprint: <https://ietresearch.onlinelibrary.wiley.com/doi/pdf/10.1049/iet-smc.2019.0024>. URL: <https://ietresearch.onlinelibrary.wiley.com/doi/abs/10.1049/iet-smc.2019.0024>.
- [27] Deuk-Young Jeong et al. “Digital Twin: Technology Evolution Stages and Implementation Layers With Technology Elements”. In: *IEEE Access* 10 (2022), s. 52609–52620. DOI: 10.1109/ACCESS.2022.3174220.
- [28] David Jones et al. “Characterising the Digital Twin: A systematic literature review”. In: *CIRP Journal of Manufacturing Science and Technology* 29 (2020), s. 36–52. ISSN: 1755-5817. DOI: <https://doi.org/10.1016/j.cirpj.2020.02.002>. URL: <https://www.sciencedirect.com/science/article/pii/S1755581720300110>.
- [29] Michael Grieves. “Digital Twins: Past, Present, and Future”. In: máj 2023, s. 97–121. ISBN: 978-3-031-21342-7. DOI: 10.1007/978-3-031-21343-4.
- [30] Mahnoor Yaqoob, Ramona Trestian a Huan X. Nguyen. “Leveraging Digital Twin Approach for Network Slicing in B5G Network”. In: *2023 IEEE International Conference on Communications Workshops (ICC Workshops)*. 2023, s. 242–247. DOI: 10.1109/ICCWorkshops57953.2023.10283758.
- [31] Nour Alqudah a Qussai Yaseen. “Machine Learning for Traffic Analysis: A Review”. In: *Procedia Computer Science* 170 (2020). The 11th International Conference on Ambient Systems, Networks and Technologies (ANT) / The 3rd International Conference on Emerging Data and Industry 4.0 (EDI40) / Affiliated Workshops, s. 911–916. ISSN: 1877-0509. DOI: <https://doi.org/>

- 10.1016/j.procs.2020.03.111. URL: <https://www.sciencedirect.com/science/article/pii/S1877050920305494>.
- [32] Giang Nguyen Thu. *Introduction to data science*. Vydavateľstvo SPEKTRUM STU, 2022. ISBN: 978-80-227-5193-3. URL: https://kis.cvt.stuba.sk/ar1-stu/sk/detail-stu_us_cat-0095495-Introduction-to-data-science/.
- [33] Chengliang Chai et al. “Mitigating Data Scarcity in Supervised Machine Learning Through Reinforcement Learning Guided Data Generation”. In: *2024 IEEE 40th International Conference on Data Engineering (ICDE)*. 2024, s. 3613–3626. DOI: 10.1109/ICDE60146.2024.00278.
- [34] Timothy D. West a Mark Blackburn. “Is Digital Thread/Digital Twin Affordable? A Systemic Assessment of the Cost of DoD’s Latest Manhattan Project”. In: *Procedia Computer Science* 114 (2017). Complex Adaptive Systems Conference with Theme: Engineering Cyber Physical Systems, CAS October 30 – November 1, 2017, Chicago, Illinois, USA, s. 47–56. ISSN: 1877-0509. DOI: <https://doi.org/10.1016/j.procs.2017.09.003>. URL: <https://www.sciencedirect.com/science/article/pii/S1877050917317970>.
- [35] Sumit Singh et al. “Challenges of Digital Twin in High Value Manufacturing”. In: *SAE International - Aerospace Systems and Technology Conference 2018, London*. Okt. 2018. DOI: 10.4271/2018-01-1928.
- [36] Marc-Roger Gagné. *Digital Twins, Another Reason to Worry About the IoT and Data Security*. <https://irishtechnews.ie/digital-twins-iot-and-data-security/>. 2022.
- [37] Rui Carvalho a Alberto Rodrigues da Silva. “Sustainability Requirements of Digital Twin-Based Systems: A Meta Systematic Literature Review”. In: *Applied Sciences* 11.12 (2021). ISSN: 2076-3417. DOI: 10.3390/app11125519. URL: <https://www.mdpi.com/2076-3417/11/12/5519>.

- [38] Christopher Tozzi. *Why Docker containers are good for the environment*. <https://cloudnativenow.com/features/docker-containers-good-environment/>. 2017.
- [39] Edrian Blasquino. *Docker forensics for sustainability: Unraveling the environmental impact of containerized systems*. <https://eforensicsmag.com/docker-forensics-for-sustainability-unraveling-the-environmental-impact-of-containerized-systems/>. 2023.
- [40] Yunlong Lu et al. “Communication-Efficient Federated Learning for Digital Twin Edge Networks in Industrial IoT”. In: *IEEE Transactions on Industrial Informatics* 17.8 (2021), s. 5709–5718. DOI: 10.1109/TII.2020.3010798.
- [41] Diego M. Botín-Sanabria et al. “Digital Twin Technology Challenges and Applications: A Comprehensive Review”. In: *Remote Sensing* 14.6 (2022). ISSN: 2072-4292. DOI: 10.3390/rs14061335. URL: <https://www.mdpi.com/2072-4292/14/6/1335>.
- [42] Umar Danjuma Maiwada, Kamaluddeen Usman Danyaro a Aliza Bt Sarlan. “Enhancing 5G energy efficiency through digital twin networks: A comprehensive review”. In: *Digital Twins and Applications* 1.1 (2024), s. 4–25. DOI: <https://doi.org/10.1049/dgt2.12008>. eprint: <https://ietresearch.onlinelibrary.wiley.com/doi/pdf/10.1049/dgt2.12008>. URL: <https://ietresearch.onlinelibrary.wiley.com/doi/abs/10.1049/dgt2.12008>.
- [43] James Durand, Cassandra Telenko a Carolyn Seepersad. “How Does Modularity Affect Green Design?” In: *Proceedings of the ASME 2010 International Design Engineering Technical Conferences Computers and Information in Engineering Conference IDETC/CIE 2010*. Zv. 6. Aug. 2010. DOI: 10.1115/DETC2010-28760.

A Používateľská príručka

Používateľská príručka

Platformy a kompatibilita

- macOS Sequoia 15.4
- Ubuntu 22.04.3 LTS
- Windows 11 Home s nainštalovaným WSL2

Požiadavky

Git (verzia 2.39.5), Docker (verzia 28.0.1)

Inštalácia a spustenie systému

1. Klonujte repozitár a prejdite do adresára projektu:

```
git clone https://github.com/xtruhlar/5GDigitalTwin.git  
cd 5GDigitalTwin/Implementation
```

2. Vytvorte Docker obrazy:

```
cd ./base
docker build -t docker_open5gs .

cd ../ueransim
docker build -t docker_ueransim .

cd ..
```

3. Nastavte premenné prostredia:

```
cp .env.example .env

set -a
source .env
set +a
```

4. Spustite celý systém pomocou Docker Compose:

```
docker compose -f deploy-all.yaml up --build -d
```

5. Naimportujte preddefinovaných účastníkov do MongoDB:

```
docker exec -it mongo mkdir -p /data/backup
docker cp ./mongodb_backup/open5gs mongo:/data/backup/open5gs
docker exec -it mongo mongorestore \
  --uri="mongodb://localhost:27017" \
  --db open5gs /data/backup/open5gs
```

6. Overté funkčnosť jadra siete cez Open5GS WebUI:

Otvorte `http://localhost:9999` Prihlásenie:

Meno: `admin`

Heslo: `1423`

7. Spustite UERANSIM gNB:

```
docker compose -f nr-gnb.yaml -p gnodeb up -d && \
docker container attach nr_gnb
```

8. Pripojte registrované zariadenie (UE):

```
docker compose -f nr-UEs/nr-ue1.yaml -p ues up --build -d
```

9. Vizualizácia klasifikovaného stavu 5G siete: Otvorte Grafanu na `http://localhost:3000` Prihlásenie:

Meno: `open5gs`

Heslo: `open5gs`

Potom kliknite na `Dashboards` → `Current state Dash`

B Harmonogram práce

B.1 Zimný semester

1. - 5. týždeň	Konzultácie, rešerš problematiky
6. týždeň	Formulácia problému
7. týždeň	Technický literárny prehľad
8. týždeň	Konzultovanie, Zamestnateľnosť
9. - 10. týždeň	Implementovanie pripomenutých zmien, Hodnotenie rizík, Udržateľnosť a environmentálny dopad
11. týždeň	Návrh riešenia na vysokej úrovni
12. týždeň	Úvod, Konzultovanie, Implementovanie pripomenutých zmien, Odovzdávanie BP 1

B.1.1 Vyjadrenie k harmonogramu

Harmonogram sa dodržal, čo prispelo k systematickému a plynulému postupu pri spracovaní bakalárskej práce. Pravidelné konzultácie s vedúcim práce zohrali kľúčovú úlohu pri jej realizácii. Vedúci poskytoval pripomienky a odporúčania, na základe ktorých sa jednotlivé časti práce mohli upraviť do súčasnej podoby. Tento

proces mi umožnil efektívne riešiť prípadné nedostatky a zabezpečiť súčasnú kvalitu výsledného dokumentu.

B.2 Letný semester - Predbežný plán

Týždeň	Bakalárska práca	Článok
1. - 2. týždeň	Tímová práca, diverzita a inklúzia, konzultovanie o implementácií	Related work
3. - 4. týždeň	Open5GS, UERANSIM, srsRAN, Zber dát	Introduction, Methods, Index Terms
5. - 7. týždeň	Zber dát, Konfigurácia, MATLAB a Simulink	Data and Material
8. - 10. týždeň	ML model, trénovanie, Experimentálna reprodukovateľnosť a integrácia	About author, Discussion
11. týždeň	Konzultovanie, implementácie pripomienkovaných zmien, technický abstrakt, laický abstrakt	Results, Abstract, Lay abstract
12. týždeň	Zhrnutie, úpravy, konzultovanie	Conclusion, Future work

C Obsah digitálneho média

Evidenčné číslo práce v informačnom systéme: FIIT-16768-120897

Obsah digitálnej časti práce (archív ZIP):

Folder	Contents
/bin	binárne súbory umožňujúce ...
/service	
/app	
/models	modely opísané v práci
modelA	
modelB	
/scripts	
/data	dátové množiny použité na ...
/praca-pdf	pdf verzia záverečnej práce
/praca.pdf	pdf hlavná časť záverečnej práce
/prilohy.pdf	pdf textové prílohy záverečnej práce

Názov odovzdaného archívu: BP_prilohy_digital_JanoMrkvicka.zip.