

Digitálne Dvojča 5G Siete a Doménový Prenos: Klasifikácia Sieťového Správania zo Simulácií do Reality

David Truhlár

Fakulta informatiky a informačných technológií, Slovenská technická univerzita v Bratislave
Ilkovičova 2, 842 16 Karlova Ves, Bratislava, Slovenská republika
xtruhlar@stuba.sk

Abstrakt—Siete piatej generácie (5G) predstavujú základnú infraštruktúru pre aplikácie s prísnyimi požiadavkami na odozvu a spoľahlivosť. Technológia digitálneho dvojčata (DT) má v tomto kontexte potenciál slúžiť ako adaptívna vrstva pre simuláciu a klasifikáciu sieťovej prevádzky. Táto práca sa zameriava na návrh a implementáciu DT 5G siete, ktoré v reálnom čase analyzuje metriky jadra siete a klasifikuje aktuálny typ prevádzky pomocou rekurentných neurónových sietí (LSTM). Navrhnuté riešenie pozostáva zo simulačného prostredia založeného na voľne dostupných programoch, doplneného o klasifikačný model. V rámci experimentov boli vygenerované syntetické dáta v šiestich definovaných používateľských scenároch a získané reálne dáta z fyzickej siete. Bol navrhnutý robustný výber metrík s cieľom identifikovať znaky vhodné pre klasifikáciu v oboch doménach. Modely boli trénované výhradne na syntetických dátach, pričom ich presnosť bola následne vyhodnotená na reálnych dátach. DT preukázalo technickú funkčnosť, je schopné v reálnom čase zbierať dáta, klasifikáciu a aktualizovať model pomocou jemného doladenia bez prerušenia prevádzky. Výsledky ukazujú, že samotná infraštruktúra DT je technologicky udržateľná, avšak účinné správanie klasifikačného modelu si vyžaduje pokročilejšie techniky adaptácie medzi doménami.

Kľúčové slová: 5G, Digitálne dvojča, Prenos medzi doménami, Klasifikácia sieťového stavu

I. Úvod

Technológia digitálneho dvojčata (DT) je koncept, ktorý umožňuje vytvárať dynamické virtuálne repliky fyzických systémov s cieľom zrkadliť ich stav a správanie v reálnom čase [1], [2]. Svoje uplatnenie si DT našli v rôznych doménach od výroby, cez zdravotníctvo až po energetiku [3], kde slúžia na monitorovanie, prediktívnu údržbu a optimalizáciu procesov.

V oblasti komunikačných sietí, najmä pri rozvoji infraštruktúr piatej generácie (5G), DT predstavujú perspektívne riešenie na bezpečné testovanie,

sledovanie a riadenie dynamických sieťových konfigurácií [3]. 5G siete sú charakteristické nízkou latenciou a náročnosťou na kvalitu služieb (QoS), čo výrazne komplikuje ich správu a optimalizáciu. V tomto kontexte DT umožňujú simulovať rôzne prevádzkové scenáre v izolovanom prostredí bez rizika výpadkov služieb.

Kľúčovou výzvou pri návrhu DT pre 5G siete je zabezpečiť dostatočnú vernosť simulácie voči komplexným reálnym podmienkam. Osobitnú pozornosť si vyžaduje otázka generalizovateľnosti modelov strojového učenia trénovaných výlučne na syntetických dátach – problém známy ako doménový prenos (domain transfer).

Cieľom tejto práce je experimentálne overiť schopnosť jednoduchého DT klasifikovať správanie 5G siete v reálnom čase na základe synteticky generovaných metrík. Navrhnuté riešenie je postavené na voľne dostupných nástrojoch Open5GS a UERANSIM, pričom kombinuje simuláciu, dátový zber a klasifikáciu pomocou modelu s architektúrou LSTM.

II. Súvisiaca práca

Koncept DT si v poslednom desaťročí našiel uplatnenie ako nástroj na monitorovanie, optimalizáciu a inferenciu v reálnom čase naprieč rôznymi doménami [1]. Pôvodne uplatňovaný najmä v priemysle, dnes preniká aj do dátovo orientovaných sieťových architektúr.

Práca [4] predstavuje všeobecný rámec pre návrh a nasadenie DT v sieťových prostrediach, pričom zdôrazňuje dôležitosť modularity, synchronizácie dát a spätnej väzby medzi fyzickým a digitálnym svetom.

V štúdiu [5] autori prezentujú využitie synteticky generovaných dát v rámci DT simulácií komplexných infraštruktúr a preukazujú, že takéto dáta môžu výrazne urýchliť experimentovanie.

V oblasti mobilných sietí sa tejto problematike venovali autori v [6], navrhli plne emulované prostredie pre generovanie anotovaných datasetov. Práca

ukazuje, že takto vytvorené syntetické dáta môžu poslúžiť na tréovanie modelov strojového učenia v prípadoch, keď je prístup k reálnym dátam limitovaný regulačne alebo technicky.

Autori v [7] predstavili architektúru LLM-Twin, ktorá využíva veľké jazykové modely ako základ DT systémov. Tento prístup otvára nové možnosti pre interpretovateľnosť a adaptabilitu v kontexte budúcich sieťových infraštruktúr.

III. Metodológia

A. Architektúra a funkcionálna digitalizácia dvojčata

Navrhované riešenie predstavuje plne funkčné DT 5G siete, ktoré implementuje základné prvky tejto paradigmy: fyzický objekt, digitálny model a dátové prepojenie medzi nimi.

Fyzickú časť systému predstavuje experimentálne jadro 5G siete postavené na komponentoch Open5GS bežiacich v izolovanom prostredí, ku ktorému boli pripojené reálne mobilné zariadenia. Digitálnu časť tvorí kontajnerizované prostredie so simulovanými komponentmi siete (UERANSIM) [8], skriptami na generovanie kontrolovanej syntetickej prevádzky a klasifikačným modelom založeným na rekurentných neurónových sieťach typu LSTM (Long Short-Term Memory).

Dôležitým aspektom riešenia je schopnosť zrkadliť aktuálny stav siete v reálnom čase. Systém kontinuálne zhromažďuje metrické a logové údaje prostredníctvom nástroja Prometheus, interpretuje ich pomocou klasifikačného modelu a, ak sú dostupné anotované dáta, priebežne vykonáva ladenie modelu (fine-tuning). Tým sa DT stáva nielen pasívnym monitorovacím nástrojom (tzv. digitálnym tieňom), ale aj autonómne sa prispôbujúcim systémom schopným reflektovať meniace sa podmienky v reálnom čase.

Táto architektúra DT umožňuje experimentálne overenie klasifikácie sieťovej prevádzky v reálnom čase, ako aj výskum doménového prenosu medzi syntetickým a reálnym prostredím.

B. Datasets

Pre potreby tréovania a vyhodnocovania klasifikácie v reálnom čase boli v rámci navrhnutého DT vytvorené dva nezávislé datasety: jeden syntetický, založený na simuláciách, a jeden reálny, získaný z prevádzky fyzickej siete. Cieľom bolo preskúmať možnosť doménového prenosu modelov učenia výhradne na syntetických dátach, ktoré sú následne testované na dátach zo skutočnej prevádzky.

Syntetický dataset bol generovaný v plne automatizovanom prostredí postavenom na komponentoch Open5GS a UERANSIM. Bolo definovaných šesť používateľských scenárov (UC) (pozri Tabuľka I), z ktorých každý reprezentuje špecifický typ sieťového správania (napr. periodické požiadavky, súbežné sledovanie videa, odmietnutie pripojenia). Spustenie jednotlivých scenárov bolo realizované cez skripty, ktoré riadili nasadzovanie UE kontajnerov v časovo deterministickom poradí.

Počas celej simulácie boli metriky siete kontinuálne zbierané z nástroja Prometheus a logové udalosti extrahované pomocou vlastného Python skriptu. Každý časový krok bol anotovaný aktuálnou hodnotou scenára, čím sa zabezpečila synchronizácia medzi vytváranou sieťovou prevádzkou a zodpovedajúcim označením UC.

Reálny dataset bol vytvorený v experimente s fyzickými zariadeniami pripojenými do izolovanej 5G siete s rovnakým jadrom ako v simulácii. Používateľské správanie bolo iniciované manuálne a čas začiatku aj konca každého scenára bol zaznamenaný. Po každom experimente boli z disku extrahované relevantné logy Open5GS, ktoré boli následne spracované tým istým nástrojom ako v prípade syntetických dát. Anotácie UC boli priradené spätne podľa časových značiek experimentu a známeho scenára.

Oba datasety majú identickú štruktúru: časová pečiatka, metrické dáta, logové dáta a premenná s UC. Takto zvolený formát umožnil výmenu dátových zdrojov pri porovnaní výkonnosti modelov bez potreby úprav pipeline. Výstupom boli CSV súbory, pričom reálny dataset bol použitý výhradne na testovanie.

C. Architektúra a tréovanie modelov

Na účely klasifikácie sieťového správania boli navrhnuté a experimentálne overené štyri rôzne architektúry založené na rekurentných neurónových sieťach (RNN), konkrétne na LSTM (Long Short-Term Memory) bunkách [9]. Každá architektúra bola implementovaná v prostredí TensorFlow a tréovaná na rovnakých vstupných sekvenciách s dĺžkou 60 časových krokov. Všetky modely využívajú ako vstup normalizované metrické a logové dáta vektorovo reprezentované na úrovni jedného časového kroku.

- Základný model: pozostáva z dvoch po sebe idúcich LSTM vrstiev (64 a 32 jednotiek), nasledovaných výstupnou plne prepojenou (Dense) vrstvou s aktivačnou funkciou softmax. Model slúži ako referenčná architektúra.
- Robustný model: zahŕňa tri LSTM vrstvy s postupne klesajúcim počtom jednotiek

Tabuľka I: Tabuľka používateľských scenárov

Názov	Popis	Reálna využitie
Bežná prevádzka	Zariadenia sa náhodne pripájajú a od-pájajú, náhodne sťahujú malé množ-stvá dát.	Typické používanie siete, slúži ako zá-klad pre klasifikačný model.
Sledovanie videa	Zariadenia sú pripojené, na n z nich beží sledovanie videa.	Odhalenie veľkej dátovej prevádzky, možnosť prispôbiť konfiguráciu siete.
Periodický udržiavací signál (keep-alive)	Zariadenia sú pripojené, v pravidel-ných intervaloch posielajú udržiavací signál.	Simulácia a identifikácia správania sa IoT zariadení.
Krátke relácie (burst)	Zariadenia sa pripoja, stiahnu malé množstvo dát (10MB) a odpoja sa.	Situácia, keď sa očakáva len rýchla vý-mena dát (napr. aplikácia s počasím).
Záťažová registrácia	Všetky zariadenia sa pripoja súčasne.	Neštandardná situácia – môže pripo-míňať začiatok DDoS alebo chybu ap-likácie.
Neúspešná autentifikácia (neplatné IMSI)	Zariadenie sa opakovane pokúša pri-pojiť, autentifikácia zlyhá pre neplatné IMSI.	Neštandardná situácia – môže pripo-míňať útok hrubou silou na AUSF fun-kciiu.

(128-64-32) a dve plne prepojené vrstvy. Všetky vrstvy sú regularizované náhodným vypínaním neurónov (dropout) počas tréningu (hodnoty 0.1–0.15). Cieľom bolo zlepšiť generalizačnú schopnosť modelu.

- Model s normalizáciou dávky (Batch normalization): obsahuje rovnakú architektúru ako robustný model, doplnenú o normalizáciu dávky medzi LSTM a plne prepojenými vrstvami. Táto architektúra bola testovaná najmä z hľadiska stability učenia.
- Model s pozornosťou (Attention): na výstupe z poslednej LSTM vrstvy (return_sequences=True) bola aplikovaná vlastná vrstva s pozornosťou. Tá vypočíta váhované priemery výstupov v čase a umožňuje modelu selektívne sa zamerať na dôležité časti sekvencie (pozri Obr. 1).

Všetky modely boli tréňované výhradne na syntetickom datasete. Tréning prebiehal pomocou optimalizátora Adam a stratovej funkcie kategorickej entropie. Pri tréningu bol použitý váhový mechanizmus na kompenzáciu nerovnomerného rozloženia tried v dátach, pričom hodnoty boli predpočítané na základe distribúcie tried v tréningovej množine.

Pre každý model bol aktivovaný mechanizmus včasného zastavenia (early stopping) podľa validačnej chyby, s maximálnym počtom 100 epoch a batch veľkosťou 128. Najlepší model (s minimálnou validačnou stratou) bol uložený pre následné vyhodnotenie.

D. Evaluácia a doménový prenos

Hodnotenie výkonnosti modelov prebiehalo v dvoch fázach: najprv pomocou syntetických dát (validácia

na testovacej množine), následne s použitím reálneho datasetu (externé testovanie). Pre obe fázy bol použitý rovnaký reťazec spracovania (pipeline) a metriky: presnosť (accuracy), presnosť tried (precision), úplnosť (recall) a F1 skóre (F1-score).

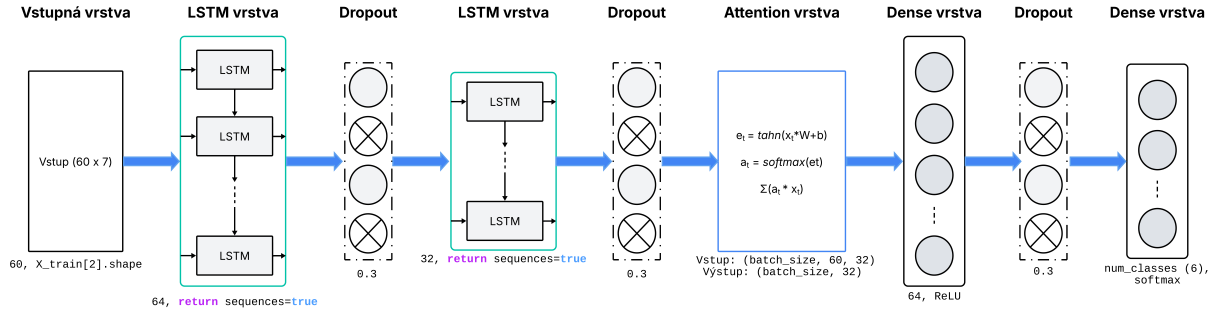
Počas tréningu modelov na syntetických dátach bola testovacia množina oddelená stratifikovaným spôsobom v pomere 80:20. Tréning zahŕňal aj použitie váh tried na základe ich početnosti v tréningových dátach. Modely boli následne hodnotené na nezávislej testovacej množine bez akéhokoľvek dodatočného doladenia.

Pre overenie schopnosti generalizácie boli natréňované modely použité bez modifikácií na reálnom datasete, pričom vstupné dáta boli normalizované pomocou škálovača (MinMaxScaler) tréňovaného výhradne na syntetických dátach. Týmto spôsobom bola zabezpečená konzistentnosť dátového formátu medzi doménami. Následne bola aplikovaná aj metóda jemného doladenia (fine-tuning) [10], pri ktorej bola malá podmnožina reálnych dát (20%) použitá na aktualizáciu váh posledných vrstiev modelov. Táto fáza zahŕňala stratifikované rozdelenie a dodržanie pôvodnej topológie bez zmien hyperparametrov.

Každý model tak prešiel tromi fázami hodnotenia:

- 1) interné testovanie na syntetických dátach (validácia generalizácie v rámci domény),
- 2) externé testovanie na reálnych dátach (doménový prenos bez úprav),
- 3) testovanie po *jemnom ladení* na reálnych dátach (adaptácia na novú doménu).

Takto definovaný evaluačný rámec umožnil kvantifikovať nielen klasifikačný výkon, ale aj robustnosť



Obr. 1: Architektúra LSTM modelu s pozornosťou, ktorá je použitá na klasifikáciu a jemné ladenie v reálnom čase vo vytvorenom DT.

modelov pri prenose medzi doménami so zásadne odlišným štatistickým rozdelením.

E. Použité technológie a knižnice

Celé riešenie bolo implementované v jazyku Python 3.11 s využitím virtualizovaného prostredia venv a kontajnerizačnej platformy Docker.

Na spracovanie a analýzu dát boli využité knižnice NumPy, Pandas a scikit-learn, zatiaľ čo definícia a tréning LSTM modelov prebehlo pomocou TensorFlow 2.15 a Keras. Vizualizácie boli generované s Matplotlib a Seaborn, monitoring siete v reálnom čase bol zabezpečený cez Prometheus a Grafana. Na serializáciu škálovacích objektov bol použitý Joblib a na spracovanie logov z Open5GS slúžila knižnica Pygtail.

Vývoj a testovanie modelov prebiehalo na osobnom počítači s procesorom Apple M3, pričom tréning modelov bolo rozdelené na dve fázy: základné tréningovanie na syntetických dátach (offline) a následné jemné ladenie na reálnych dátach (online), ktorý prebiehal v Docker kontajneri bežiacom paralelne s dátovým zberom.

IV. Výsledky a diskusia

Po natrénovaní štyroch modelov výhradne na syntetických dátach bola ich výkonnosť vyhodnotená pomocou štandardných klasifikačných metrík: presnosť (accuracy), presnosť tried (precision), úplnosť (recall) a F1 skóre (F1-score).

A. Výkonnosť LSTM modelov

V rámci syntetického datasetu dosahovali všetky modely vysoké skóre, pričom najvyššiu presnosť dosiahol model s *normalizáciou dávky* (96.2%). Prítomnosť vrstiev s regularizovaným náhodným

vypínaním neurónov (dropout) vrstiev alebo mechanizmu pozornosti (attention) prispela k miernejšiemu, no stále robustnému výkonu.

Pri aplikovaní modelov na reálny dataset bol však pozorovaný dramatický pokles výkonnosti. Žiadny z modelov nedosiahol presnosť vyššiu než 44%. Najlepšie výsledky dosiahol robustný model (44% presnosť), zatiaľ čo model s *normalizáciou dávky*, ktorý bol najpresnejší na syntetických dátach, zlyhal s presnosťou len 21% (pozri Tab. II).

B. Doménový prenos

Tieto výsledky potvrdzujú zásadný problém doménového prenosu medzi simulovanými a reálnymi sieťovými dátami. Napriek tomu, že boli použité rovnaké metrické a logové štruktúry, samotné rozloženie dát a dynamika premávky v reálnej sieti sa ukázali byť výrazne odlišné. Tento jav naznačuje, že modely tréňované výhradne na simulovaných dátach si osvojujú vzory špecifické pre syntetické prostredie a nie sú schopné generalizovať na skutočné prípady.

Aj napriek dodatočnému jemnému ladeniu modelov na podmnožine reálnych dát sme nepozorovali výrazné zlepšenie. Maximálna dosiahnutá presnosť v takomto nastavení dosiahla približne 50%, čo zodpovedá náhodnému hádaniu v kontexte viac-triednej klasifikácie so šiestimi triedami.

Tieto zistenia poukazujú na potrebu ďalšieho výskumu v oblasti doménovej adaptácie a realistickejšej simulácie sieťovej prevádzky, ktorá by mohla lepšie reprezentovať variabilitu a zložitosť reálneho prostredia.

C. Schopnosti systému v reálnom čase

Napriek obmedzenému výkonu modelov na reálnych dátach, implementovaný DT systém preukázal

Tabuľka II: Výkon klasifikácie tried pre syntetické a reálne dáta.

Model	Presnosť	Presnosť tried	F1-Skóre	Úplnosť
Syntetický dataset				
<i>Základný Model</i>	0.949	0.950	0.949	0.949
<i>Robustný Model</i>	0.900	0.905	0.900	0.900
<i>Model s Normalizáciou Dávky</i>	0.963	0.964	0.963	0.963
<i>Model s Pozornosťou</i>	0.914	0.918	0.914	0.914
Reálny dataset				
<i>Základný Model</i>	0.14	0.06	0.04	0.14
<i>Robustný Model</i>	0.44	0.25	0.29	0.44
<i>Model s Normalizáciou Dávky</i>	0.21	0.16	0.17	0.21
<i>Model s Pozornosťou</i>	0.16	0.03	0.05	0.16

svoju praktickú hodnotu. V reálnom čase spoľahlivo monitoruje stav siete, kontinuálne zhromažďuje metrické údaje, vykonáva predspracovanie dát a každú minútu aktualizuje predikciu typu sieťovej prevádzky pomocou natrénovaného modelu. Navyše, pri dostupnosti anotovaných dát je schopný vykonávať jemné ladenie modelu, čím adaptuje svoje správanie na nové alebo dynamicky sa meniace podmienky v sieti.

Táto schopnosť prispôbiť sa v reálnom čase predstavuje dôležitý krok smerom k autonómnym DT v oblasti telekomunikácií. Navrhnutá architektúra poskytuje spoľahlivý základ pre budúce experimenty s prenosovým učením (transfer learning), federatívnym učením či automatickou konfiguráciou sieťových parametrov na základe klasifikovaného správania používateľov.

V. Záver

V tejto práci bol navrhnutý, implementovaný a experimentálne overený systém DT 5G siete, ktorý v reálnom čase klasifikuje typ prebiehajúcej sieťovej prevádzky na základe metrických a logových údajov. Celý systém funguje ako autonómna jednotka: generuje syntetické dáta, trénuje LSTM modely, aplikuje ich na živé dáta a podľa potreby vykonáva jemné ladenie.

Experimentálne výsledky ukázali, že hoci modely trénované na syntetických dátach dosahujú vysokú presnosť v rámci simulovaného prostredia, ich výkonnosť na reálnych dátach je značne obmedzená. Ani po jemnom doladení na anotovaných vzorkách reálnej prevádzky sa nepodarilo dosiahnuť spoľahlivú generalizáciu. Táto skutočnosť poukazuje na prítomnosť výrazného doménového posunu medzi syntetickou a reálnou sieťovou prevádzkou.

Navrhované riešenie však predstavuje robustný základ pre ďalší výskum. Do budúca odporúčame rozšíriť systém o techniky doménovej adaptácie. DT môže zároveň slúžiť ako testovací priestor pre nové modely klasifikácie, predikcie zafarbenia siete alebo automatickú konfiguráciu parametrov 5G jadra na základe aktuálne detegovaného správania.

Literatúra

- [1] M. Enders and N. Hoßbach, “Dimensions of digital twin applications - a literature review,” 08 2019.
- [2] A. Mozo, A. Karamchandani, M. Sanz, J. I. Moreno, and A. Pastor, “B5gemini: Digital twin network for 5g and beyond,” in *NOMS 2022-2022 IEEE/IFIP Network Operations and Management Symposium*, pp. 1–6, 2022.
- [3] M. Singh, R. Srivastava, E. Fuenmayor, V. Kuts, Y. Qiao, N. Murray, and D. Devine, “Applications of digital twin across industries: A review,” *Applied Sciences*, vol. 12, p. 5727, 06 2022.
- [4] M. Sanz Rodrigo, D. Rivera, J. I. Moreno, M. Álvarez Campana, and D. R. López, “Digital twins for 5g networks: A modeling and deployment methodology,” *IEEE Access*, vol. 11, pp. 38112–38126, 2023.
- [5] B. Peterson and A. Rajuroy, “Synthetic data and digital twin integration for scalable ai simulations,” 03 2025.
- [6] G. Colonna, “Design and implementation of a 5g testbed in a virtualized environment,” master’s degree thesis, Politecnico di Torino, Turin, Italy, July 2022.
- [7] Y. Hong, J. Wu, and R. Morello, “Llm-twin: mini-giant model-driven beyond 5g digital twin networking framework with semantic secure communication and computation,” *Scientific Reports*, vol. 14, p. 19065, 2024.
- [8] S. Prasad, P. Munaweera, T. Hewa, Y. Siriwardhana, and M. Ylinattila, “Simulation of iiot-driven attack vectors on 5g core networks: Dataset generation and machine learning based detection,” in *Proceedings of the 14th International Conference on the Internet of Things*, (New York, NY, USA), p. 184–187, Association for Computing Machinery, 2025.
- [9] J. Lai, Z. Chen, J. Zhu, W. Ma, L. Gan, S. Xie, and G. Li, “Deep learning based traffic prediction method for digital twin network,” *Cognitive Computation*, pp. 1–19, 2023. Advance online publication.
- [10] L. Fernández Maimó, L. Perales Gómez, F. J. García Clemente, M. Gil Pérez, and G. Martínez Pérez, “A self-adaptive deep learning-based system for anomaly detection in 5g networks,” *IEEE Access*, vol. 6, pp. 7700–7712, 2018.